

# 機械学習(旧応用ネットワークシステム)第6回レポート

学籍番号：18t1040x 氏名:加藤正隆

## 課題

先週の課題に対して重回帰分析した結果、奇妙なことに、売り場面積 $x_3$ が売上高 $y$ に悪影響を与えているという結果が得られた。どうも納得が行かないので、今回学んだパス解析を用いて、より詳細に分析することにする。下図を参考にしつつ、売り場面積 $x_3$ が売上高 $y$ に与える影響を再考せよ。以下のプログラムを用いて、パス解析を行った。

```
import numpy as np

#標準化をする関数
def standard(array):
    return (array-np.mean(array))/np.std(array, ddof=1)

#相関係数を求める関数
def soukan(array1, array2):
    array1_h = standard(array1)
    array2_h = standard(array2)
    return np.corrcoef(standard(array1_h), standard(array2_h))[0, 1]

x1 = [8, 7, 5, 4, 6, 2, 3, 9]
x2 = [8, 7, 9, 3, 8, 3, 6, 7]
x3 = [4, 7, 8, 3, 8, 5, 6, 9]
y = [18, 12, 14, 6, 12, 8, 10, 16]

indire_31y= soukan(x3, x1)*0.4997682
indire_32y= soukan(x3, x2)*0.5970736
alleff = indire_32y+indire_31y-0.1457974

print("3->1", soukan(x3, x1))
print("3->2", soukan(x3, x2))
print(alleff)
```

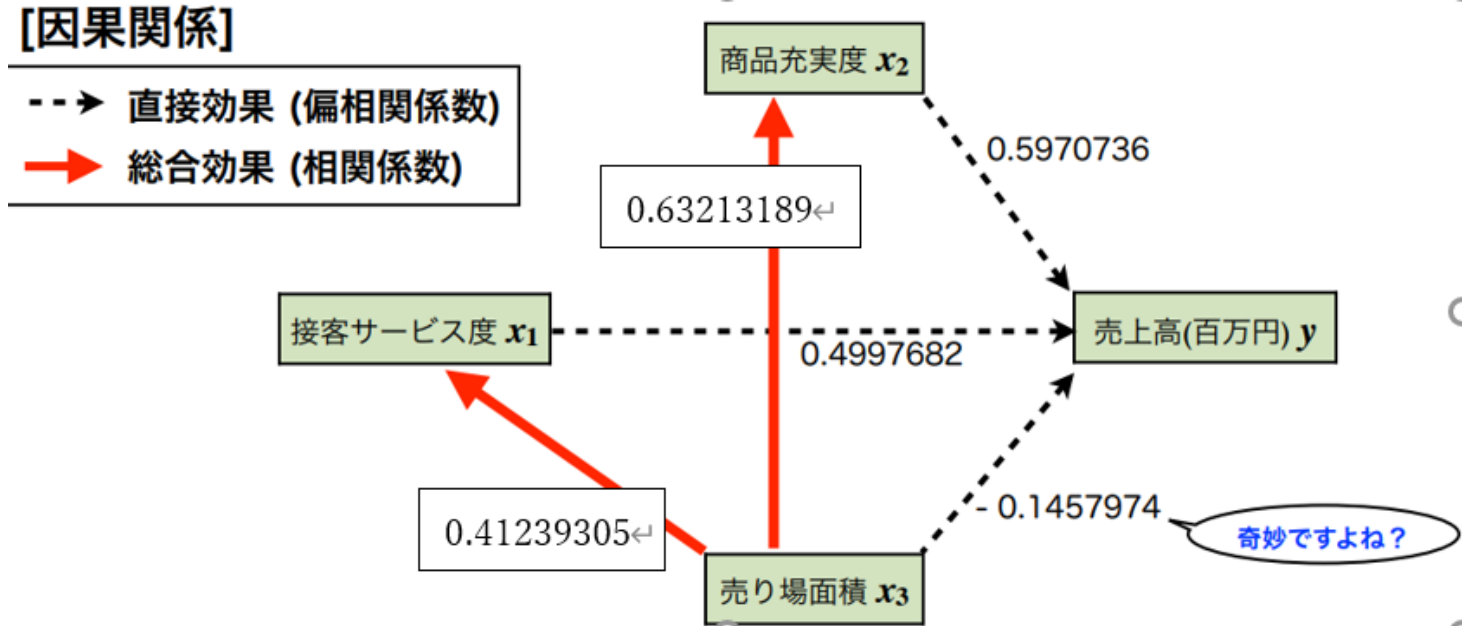
実行結果は以下の通りになった。

```
3->1 0.41239304942116134
3->2 0.6321318933586436
0.43773279724418623
```

## 結果と考察

1.  $x_3 \rightarrow y$  への直接効果 =  $-0.1457974$
2.  $x_3 \rightarrow x_1 \rightarrow y$  への間接効果 =  $0 = 412393049 \times 0.4997682 = 0.206100932$
3.  $x_3 \rightarrow x_2 \rightarrow y$  への間接効果 =  $0.632121893 \times 0.5970736 = 0.377423294292$
4. 合計 =  $-0.1457974 + 0.206100932 + 0.377423294292 = 0.43773279724418623$

パス解析の表は以下の通りになる。



## 最終結論

小型軽量 $x_3$ の間接結果によれば、売り場面積の拡大が、商品充実度を高めることになり、結果的に売上高の向上に役立っている。また、売り場面積が拡大することで、接客サービスが低下していないことが読み取れる。

## Pythonのライブラリを用いたパス解析

以下のプログラムを作製した。

```

x1_h = standard(x1)
x2_h = standard(x2)
x3_h = standard(x3)
y_h = standard(y)
N = len(y)
X_h = np.c_[np.ones(N), x1_h, x2_h, x3_h]
import statsmodels.api as sm
#モデルの設定 (最小2乗法による回帰分析)
model = sm.OLS(y_h, X_h)
#回帰分析の実行
results = model.fit()
print( results.summary() )

```

実行結果は以下の通りになった。

OLS Regression Results						
=====						
Dep. Variable:	y	R-squared:	0.834			
Model:	OLS	Adj. R-squared:	0.710			
Method:	Least Squares	F-statistic:	6.701			
Date:	Thu, 05 Nov 2020	Prob (F-statistic):	0.0487			
Time:	19:10:41	Log-Likelihood:	-3.6332			
No. Observations:	8	AIC:	15.27			
Df Residuals:	4	BIC:	15.58			
Df Model:	3					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]
-----						
const	0	0.191	0	1.000	-0.529	0.529
x1	0.4998	0.263	1.903	0.130	-0.230	1.229
x2	0.5971	0.309	1.933	0.125	-0.260	1.454
x3	-0.1458	0.263	-0.555	0.609	-0.876	0.584
=====						
Omnibus:	2.374	Durbin-Watson:	1.980			
Prob(Omnibus):	0.305	Jarque-Bera (JB):	0.815			
Skew:	-0.118	Prob(JB):	0.665			
Kurtosis:	1.455	Cond. No.	2.71			
=====						

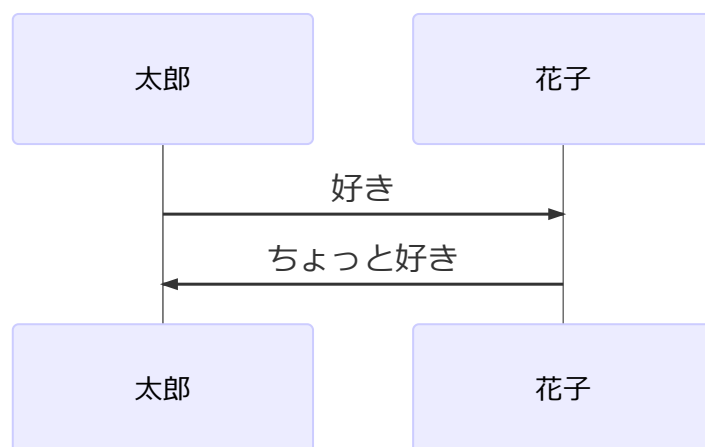
## 考察

F検定では、 $\text{Prob}(\text{F-statistic})=0.0487<0.05$ より、帰無仮説：回帰式は役に立たない、 $R^2 = 0$ , を棄却することができる。つまり、回帰式が役に立つことが分かった。t検定では、 $x_1, x_2, x_3$ のいずれの値も、0.05未満ではないため、回帰式は役に立たないと判定される。

## 参考文献

[LINGAM入門。気軽に因果関係を推定する\(統計的因果探索\)](#)

[Pythonによる因果推論と因果探索（初心者の方向け）](#)



```
import matplotlib.pyplot as plt
import numpy as np
x = np.arange(-10, 10, 0.01)
y_sin = np.sin(x)
y_cos = np.cos(x)
plt.plot(x, y_sin)
plt.plot(x, y_cos)
plt.show()
```